Генеративная ассимиляция и точность наблюдений

Часть 1: лёд, метод OA-FM
Часть 2: метод OSG на ERA5

Амир Садреев

15 октября 2026

План

1. **Лёд: метод OA-FM** — почему обычный flow matching плохо использует наблюдения и как якорные координаты это исправляют.
2. **Метод OSG на ERA5**:
   - задача, данные и два подхода: монолит и OSG;
   - как работает OSG: идея, три шага, голова, преимущества;
   - результаты против стандартного монолита: точность, использование точных наблюдений, калибровка (ранговые гистограммы), коррелированные ошибки.

Все числа по ERA5 — проверочный 2019 год. Закрытый тест 2020 года не открыт.

Часть 1. Лёд: метод OA-FM

Теория из доклада 6 октября: почему обычный flow matching плохо использует наблюдения и как это исправить

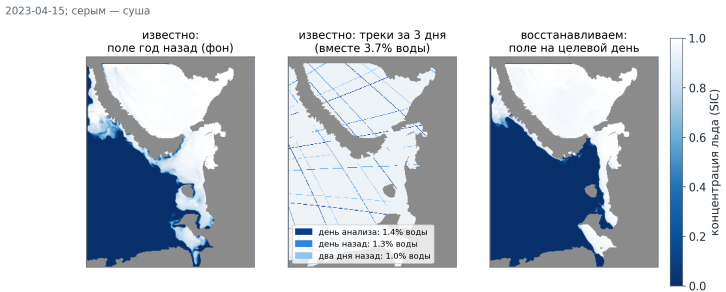
Постановка задачи

Восстановить поле концентрации льда x (Баренцево и Карское моря, модель NEMO) на заданный день по

- фону x_b — полю той же даты год назад;
- наблюдениям $y = Hx$ на треках альтиметра SRAL за 3 дня (около 1.3% площади воды в день).

Оцениваем распределение $p(x \mid y, x_b)$ ансамблем:

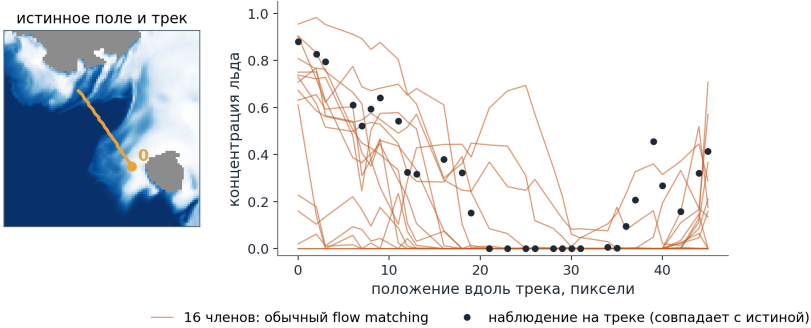
- среднее — точечная оценка;
- разброс — неопределённость;
- доля членов со льдом — вероятность льда.



Conditional flow matching

- Путь от шума к полю: $x_t = (1 - t)\,\xi + t\,x$, $\xi \sim \mathcal{N}(0, I)$, $t \in [0, 1]$.
- Сеть $v_\theta(x_t, t, c)$ обучается на $\mathbb{E}\,\|v_\theta - (x - \xi)\|^2$; оптимум — $\mathbb{E}[x - \xi \mid x_t, c]$.
- Условие c: фон, значения и маски наблюдений, маска воды, координатная сетка.
- Генерация: ОДУ $\dot{x} = v_\theta$ от $t = 0$ до $t = 1$ (Heun, 32 шага); 16 членов ансамбля из 16 начальных шумов.
- Сеть — U-Net; около половины обучающих примеров — синтетические треки.
- Данные: обучение 2016–2021, выбор модели 2022, тест 2023.

Обычный flow matching плохо использует треки



- Значение на треке задано точно, но члены ансамбля проходят мимо него: ошибка на треках .12, вдали от треков .23.
- Треки — около 4% пикселей воды, и их вклад в функцию потерь мал.
- Это не нехватка информации: среднее идеального генератора — байесовская оценка, и оно не хуже простой копии наблюдения (RMSE .064). У сети — .124.

2022 год, точные наблюдения: значение на треке совпадает с истиной. Ошибка — RMSE одного члена, среднее по 14 дням.

Растянутая шкала концентрации

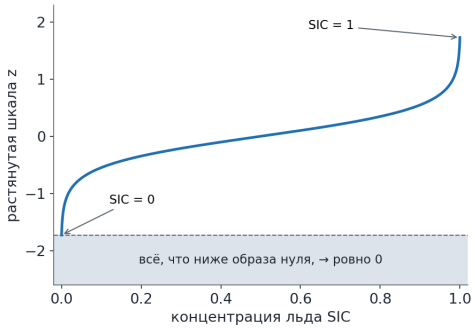
Около 55% пикселей воды — ровно 0, плотный пак сосредоточен у 1. Непрерывный генератор размазывает ноль в малые положительные значения и выносит пак за 1.

Поэтому концентрация генерируется в растянутой шкале

$$z = \tfrac{1}{4}\,\mathrm{logit}\Big(\frac{\mathrm{SIC}+\varepsilon}{1+2\varepsilon}\Big), \qquad \varepsilon = 10^{-3},$$

$$\mathrm{SIC} = \mathrm{clip}\big((1+2\varepsilon)\,\sigma(4z) - \varepsilon,\ 0,\ 1\big).$$

Края шкалы растянуты: значения у 0 и у 1 далеко разнесены. Всё, что сеть выдала ниже образа нуля, переходит ровно в 0.



Координаты, привязанные к наблюдениям (OA-FM)

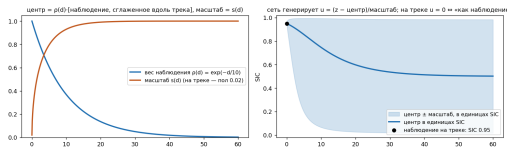
Мотивация. Ширина апостериорного распределения z на треке равна ошибке наблюдения $r \ll 1$, вдали от треков — порядка 1. Поле скоростей должно сжимать ансамбль в $1/r$ раз на 4% пикселей, и обученная сеть этого не делает.

Идея. Генерировать нормированное отклонение от гауссовой оценки по ближайшему треку:

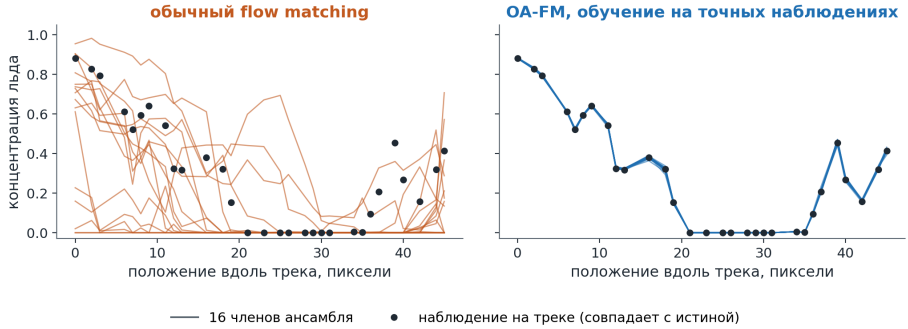
$$u = \frac{z - m}{s}, \qquad m = \rho\,\tilde{y}, \qquad s = \sqrt{1 - \frac{\rho^2}{1 + r^2}}, \qquad \rho = e^{-d/\ell}.$$

Это оптимальная интерполяция для поля $\mathcal{N}(0,1)$, коррелированного с треком с коэффициентом ρ; d — расстояние до трека, $\ell = 10$ пикселей.

- В координатах u условная ширина порядка 1 везде: сжимать ансамбль сети не нужно.
- Ошибка сети δu даёт $\delta z = s\,\delta u$; на треке $s \approx r$ — наблюдение испортить нельзя.
- Вдали $\rho \to 0$ и $u = z$ — обычная генерация.



У трека: обычный flow matching и OA-FM



- Тот же трек: все 16 членов OA-FM проходят через наблюдение. Ошибка на треках .12 → .001, вдали от треков .23 → .17.
- Если учить на точных наблюдениях, ансамбль на треках становится слишком уверенным (SSR .03); обучение с моделью ошибки наблюдений даёт SSR .65.

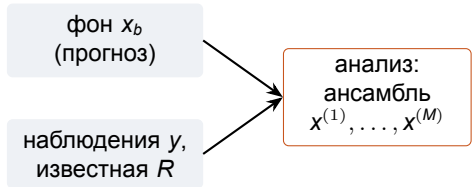
Во второй части та же идея — якорные координаты — на ERA5. Там видно и то, чего она не решает.

Часть 2. Как учесть точность наблюдений: метод OSG

ERA5: реальная сеть станций, синтетические наблюдения

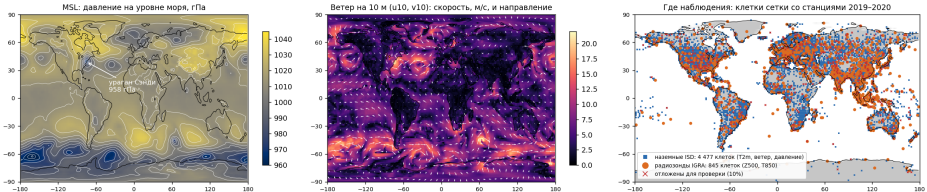
Задача: анализ как апостериорное распределение

- Есть **фон** x_b — прогноз на 24 ч, и **наблюдения** $y = Hx + \varepsilon$ в отдельных точках (H выбирает наблюдаемые величины).
- Ошибка наблюдений известна: $\varepsilon \sim \mathcal{N}(0, R)$. R — насколько можно верить каждому прибору и как связаны ошибки соседних.
- Нужен **ансамбль** из апостериора $p(x \mid x_b, y)$: среднее — лучшая оценка, разброс — неопределённость.
- R меняется: другие приборы, другая точность, коррелированные ошибки. Генеративная модель должна **правильно** на это реагировать.



Главный вопрос: **как R должна попадать в генеративную модель**.

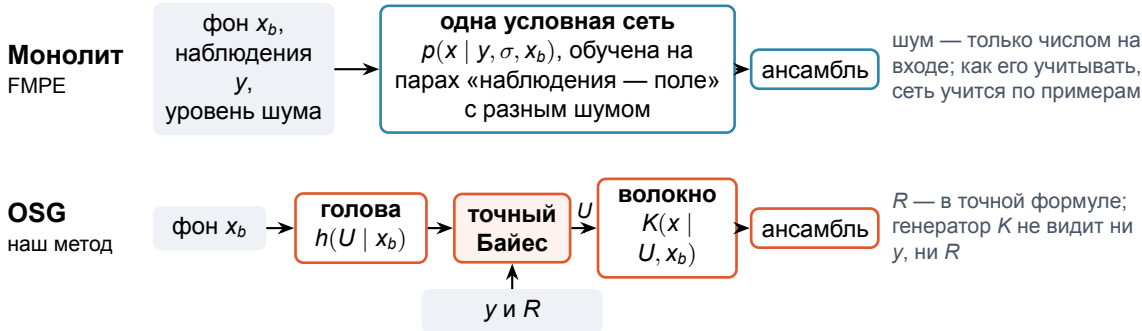
Данные: ERA5, прогноз-фон и сеть станций



30 октября 2012: давление у поверхности (ураган Сэнди), ветер у земли и клетки сетки со станциями.

- **Поле** x: ERA5, сетка $1.5°$ (121×240), 6 величин: z500, t850, t2m, ветер u10/v10, давление msl.
- **Фон** x_b: прогноз на 24 ч нейросетевым эмулятором погоды (UNet) от истинного состояния сутки назад. Ошибка: z500 ≈15 м, t850 1.1 K, t2m .9 K, ветер 1.5 м/с, msl 1.5 гПа — в 3–4 раза меньше, чем у «вчерашнего поля». Оцениваемый год эмулятор не видел.
- **Станции**: фиксированная реальная сеть (радиозонды IGRA, наземные ISD), 19 598 значений; 10% клеток отложены для проверки. Наблюдение = правда + шум.
- **Шум** сравним с ошибкой фона (z500 ≈10 м, t850 1 K, t2m 1.5 K, ветер 1.5 м/с, msl 1 гПа). Точность меняем множителем: «$\sigma \times \lambda$».
- Обучение 1979–2018, проверка 2019, тест 2020 закрыт.

Два подхода



На чём учились. У всех одна архитектура (UNet, 19 млн параметров), те же годы (1979–2018), фоны и сети станций. **Монолит**: **одна сеть на все уровни шума**; пары «наблюдения + уровень шума $\rightarrow$ поле», шум $= \sigma_0 \cdot \lambda$ со случайным λ от .03 до 1, λ подаётся на вход числом. **OSG**: K — на парах «истинные U — истинное поле», без шума. U — значения в клетках фиксированной сети станций (19 598 чисел).

OSG: идея

Наблюдения зависят от поля **только через значения в станциях** U: $y = HU + \varepsilon$. Тогда по формуле Байеса апостериор **точно** раскладывается на два множителя:

$$p(x \mid x_b, y) \;=\; \underbrace{p(U \mid x_b, y)}_{\substack{\text{станции:}\\ \text{вся информация о } y \text{ и } R}} \;\cdot\; \underbrace{p(x \mid U, x_b)}_{\substack{\text{поле по станциям:}\\ \text{о } y \text{ и } R \text{ не знает}}}$$

- **Первый множитель** — маленькая задача в станциях: гауссов prior + известная R = точная формула для **любой** R.
- **Второй множитель** — генеративная модель K: как достроить поле по точным значениям в станциях. Учится один раз на парах «истинные U — истинное поле», без шума наблюдений.

Почему это верно.
$p(x \mid x_b, y) \propto p(y \mid U)\, p(x \mid x_b)$ и
$p(x \mid x_b) = p(U \mid x_b)\, p(x \mid U, x_b)$.
Множитель $p(y \mid U)$ касается только U:

$$p(x \mid x_b, y) \propto \left[p(y \mid U)\, p(U \mid x_b)\right] p(x \mid U, x_b).$$

Это не приближение: если голова и K точны, ансамбль OSG — точный апостериор при любой R.

OSG: три шага

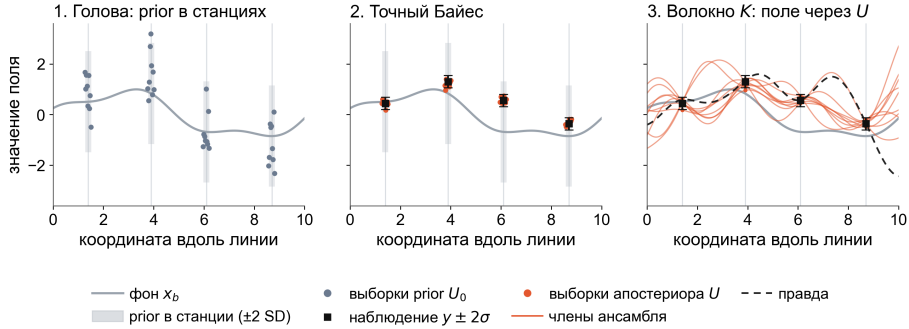


Иллюстрация на гауссовом процессе, а не на ERA5.

1. **Голова** $h(U \mid x_b)$: гауссов prior в станциях по всему полю фона (подробнее — следующий слайд).
2. **Точный Байес** (правило Матерона): $U = U_0 + CH^\top (HCH^\top + R)^{-1}(y + \varepsilon - HU_0)$, $U_0 \sim h$, $\varepsilon \sim \mathcal{N}(0, R)$ — точная выборка апостериора; тот же шаг, что в EnKF, но только в станциях.
3. **Волокно** $K(x \mid U, x_b)$: генерирует остальное поле как приращение к фону. Значения в станциях оно **не генерирует, а закрепляет** — сжимать ансамбль сети не нужно. Это выборки шага 2: у каждого члена свои U, шум наблюдений уже учтён.

Голова $h(U \mid x_b)$: чего ждать от ошибки фона в станциях сегодня

Гауссово распределение для 19 598 значений в станциях, в единицах приращения $a = (U - x_b)/s_b$: **насколько и как фон ошибается в станциях в этот срок**. Аналог матрицы *B* из 3D-Var, но только в станциях и зависящий от погоды:

$$a \sim \mathcal{N}\left(\mu + \delta,\ \ D\,C_L\,D + FF^{\top}\right).$$

- μ, C_L — статическая часть: средняя ошибка фона и её ковариация по обучающим годам; C_L сглажена локализацией.
- δ — сдвиг: систематическая ошибка фона сегодня.
- *D* — масштабы от .61 до 1.65: где фон сегодня надёжнее или хуже обычного.
- *F* — 16 «погодных мод»: сегодняшние связанные ошибки соседних станций.

Откуда δ, *D*, *F*: их даёт UNet по всему полю фона (плюс рельеф, суша/море, время). Наблюдения *y* и *R* на вход **не подаются**.

Обучение: максимум правдоподобия истинных приращений в станциях (1979–2018).

Почему гауссова: тогда шаг Байеса точный и дешёвый.

Что даёт погода: апостериор в станциях на 12% точнее по CRPS, чем со статической головой.

Ограничение: хвосты гауссовы — на редких больших невязках ($\geq 3\sigma$) станции хуже на 2.5–4.6%.

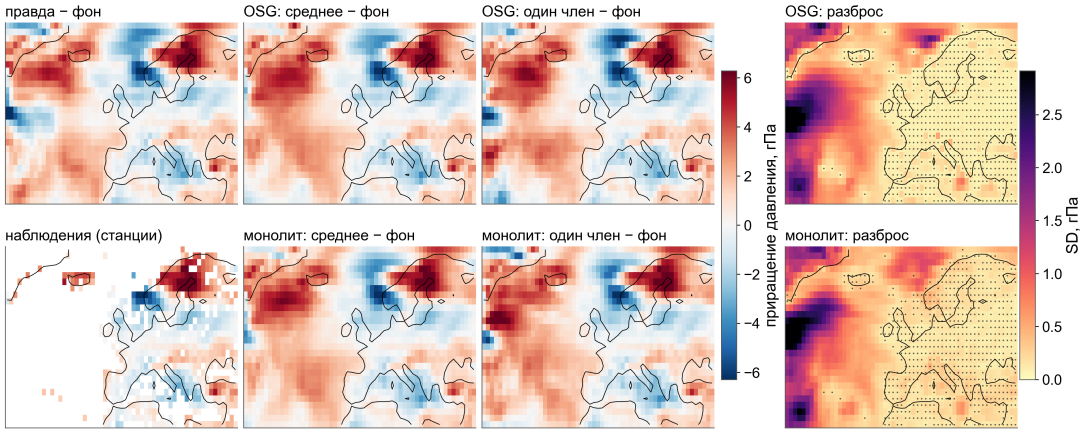
Преимущества OSG

- **Любая R без переобучения**: другая точность, неоднородный шум, коррелированные ошибки — меняется только формула шага 2.
- **Точные наблюдения используются полностью**: при $R \to 0$ шаг 2 возвращает наблюдения; сжимать ансамбль генератору не нужно.
- **Генератор учится один раз и без шума**.
- **Цена как у монолита**: 6.2 с на срок против 5.65 с (16 членов, V100).

Ограничения

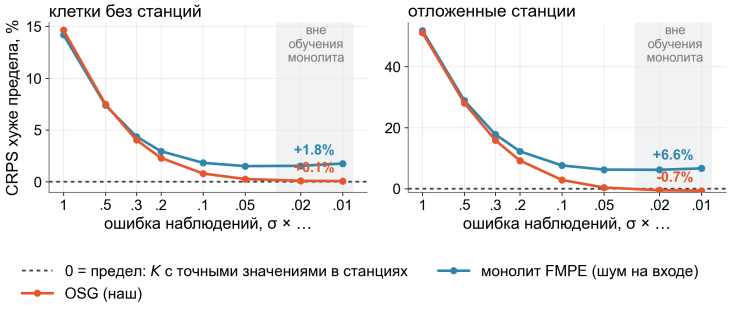
- Голова гауссова: на редких больших невязках станции хуже.
- Наблюдения — на фиксированной сети станций ($y = HU + \varepsilon$).

Пример анализа: точные наблюдения ($\sigma \times .1$)



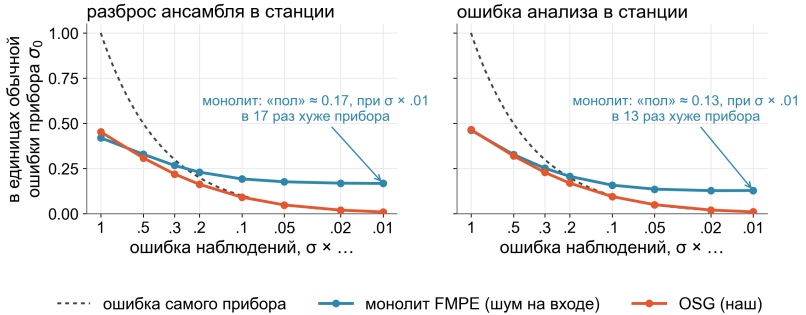
1 января 2019, давление у поверхности, Северная Атлантика и Европа; точки — станции. Оба метода восстанавливают приращение там, где есть станции; разброс мал над сушей со станциями и велик над океаном. По одной карте методы почти не различить — разница видна в статистике по 67 срокам.

Результат 1. Точность при разной ошибке наблюдений



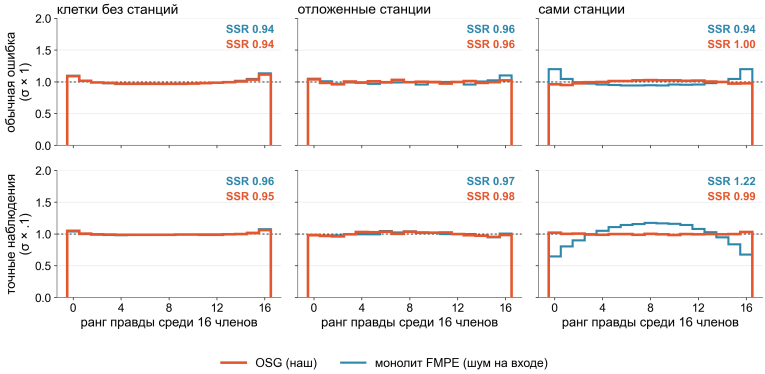
- **Как читать**: насколько CRPS хуже **предела** — *K* с точными значениями в станциях (0 — лучше не бывает).
- **Обычная ошибка** ($\sigma \times 1$): все на ≈15% хуже предела; монолит точнее OSG на .4%, но при разной точности станций по регионам OSG лучше на .9% (монолит видит только общий уровень шума).
- **Точные наблюдения**: OSG доходит до предела, монолит застревает выше — +1.8% по полю и +6.6% на отложенных станциях при $\sigma \times .01$.

Почему монолит не использует точные наблюдения



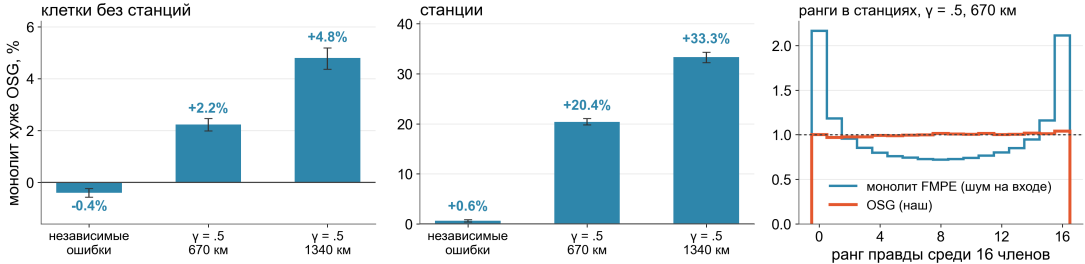
- **Как читать**: разброс ансамбля и ошибка анализа в самих станциях; пунктир — ошибка самого прибора. Хороший анализ не хуже прибора: при обычной ошибке лучше (помогают фон и соседние станции), при точных наблюдениях — на уровне прибора.
- OSG идёт вниз вместе с прибором (шаг 2). Монолит упирается в «пол» и при $\sigma \times .01$ в 13–17 раз хуже прибора — та же проблема, что с треками во льду.

Результат 2. Калибровка: ранговые гистограммы



- **Как читать**: ранг правды среди 16 членов. Ровно на уровне 1 — разброс честный; ∪ — ансамбль слишком уверен; ∩ — слишком широк. SSR — разброс / ошибка, 1 — честно.
- В поле и на отложенных станциях оба метода откалиброваны. В самих станциях монолит — нет: при обычной ошибке ∪, при точных наблюдениях ∩ (SSR 1.22) — он не может сжаться. OSG ровный везде.

Результат 3. Коррелированные ошибки наблюдений



- Ошибки соседних станций связаны: $R = D[(1-\gamma)I + \gamma C_\ell]D$, γ — доля общей ошибки, длина связи ≈670 или 1340 км (модель ошибок задана нами). OSG подставляет полную R в шаг 2, монолит знает только уровень шума.
- При $\gamma = .5$ монолит хуже OSG на 2.2–4.8% по полю и на 20–33% на станциях; в станциях он слишком уверен (∪), OSG ровный.
- Если монолит **переобучить** на коррелированных ошибках, по полю он догоняет OSG (паритет на 670 км, OSG лучше на .4% на 1340 км); OSG точнее в станциях на 1–3% — и обходится без переобучения.

Итог

Что показали (ERA5, проверочный 2019 год; OSG против стандартного монолита)

1. OSG применяет известную ошибку наблюдений точно и без переобучения: генератор учится один раз, R входит формулой.
2. Точные наблюдения: OSG выходит на предел «K с точными значениями в станциях»; стандартный монолит застревает выше (+1.8% по полю, +6.6% на отложенных станциях), потому что не умеет сжать ансамбль в станциях: там он в 13–17 раз хуже прибора.
3. Калибровка: OSG ровный везде; монолит в станциях — нет.
4. Коррелированные ошибки: OSG лучше монолита на 2.2–4.8% по полю без переобучения; переобученный монолит догоняет его по полю, но не в станциях.
5. Специалист, обученный только на точных наблюдениях, на своём шуме почти догоняет OSG (на .3%), но на другие уровни шума не переносится.

Честно: при однородном номинальном шуме монолит на .4% точнее; голова гауссова; сеть станций фиксирована; наблюдения синтетические; тест 2020 ещё не открыт.

Дальше: заморозка и закрытый тест 2020; реальные наблюдения; лёд как второй домен; статья.